



**Tecnológico
de Monterrey**

**Proyecto integrador:
Avance 2. Ingeniería de características.**

Misael López Sánchez A01796906

**Proyecto Integrador MNA 2026
Equipo 18**

Partner:
Dra. Anthony Rios

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales

08/Enero/2026

Table of Contents

1. Introducción2

2. De ingeniería manual a aprendizaje de representaciones3

3. Transformación y codificación de datos de Entrada (Encoding)3

4. Ingeniería de variable Objetivo (Target Discretation)4

5. Extracción de características latentes (Feature extraction)5

6. selección de características y reducción de dimensionalidad.....7

Conclusiones:7

Anexos:8

Tabla de figuras:

Ilustración 1 Flujo de la ingeniería de representaciones del proyecto.3

Ilustración 2 Proceso de creación de características y tokenización.4

Ilustración 3 Extracción de características.6

1. Introducción

La fase de Ingeniería de Características (*Feature Engineering*) constituye el puente crítico entre los datos crudos procesados y los algoritmos de aprendizaje automático. Su objetivo tradicional es transformar la información disponible en un conjunto de variables numéricas que maximicen el rendimiento predictivo del modelo.

No obstante, dado que esta investigación se fundamenta en Grandes Modelos de Lenguaje (LLMs) y datos no estructurados, el enfoque clásico de selección manual de variables se redirige hacia la **Ingeniería de Representaciones** (*Representation Learning*). En este paradigma; las "características" no son atributos tabulares explícitos, sino vectores densos en un espacio latente multidimensional que codifican propiedades semánticas y sintácticas complejas.

En la presente sección, se documenta la metodología utilizada para transformar las consultas textuales en secuencias de *tokens*, discretizar las métricas de evaluación en etiquetas de supervisión, y fundamentalmente, extraer los tensores de activación interna del modelo Llama 3. Estas operaciones matemáticas son indispensables para construir los **Vectores de Dirección** (*Steering Vectors*), los cuales servirán como la herramienta principal de intervención en las etapas subsecuentes de experimentación.

2. De ingeniería manual a aprendizaje de representaciones

En el contexto de la minería de datos tradicional, la ingeniería de características implica la construcción manual de variables explicativas. Sin embargo, dado que este proyecto opera sobre modelos de lenguaje masivos (LLMs) y datos no estructurados. Se adopta el paradigma de **Ingeniería de Representaciones** (*“Representation Engineering”*). En este enfoque, las "características" no son atributos escalares aislados, sino vectores densos en un espacio latente multidimensional. Por lo tanto, los procesos de transformación, codificación y reducción dimensional se han adaptado para operar sobre tensores de activaciones neuronales y *embeddings* semánticos, en cumplimiento con los objetivos de interpretabilidad del mecanismo de *Activation Steering*.




Ilustración 1 Flujo de la ingeniería de representaciones del proyecto.

3. Transformación y codificación de datos de Entrada (Encoding)

Para convertir la información cruda almacenada en las bases de datos relacionales en insumos procesables por la red neuronal, se aplicaron dos niveles de transformación secuencial:

1. **Construcción de Características Textuales (Prompt Construction):** Se realizó una transformación de datos estructurados a no estructurados. Las tripletas semánticas $T = (\text{Sujeto}, \text{Predicado}, \text{Objeto})$ fueron convertidas en cadenas de texto natural Q mediante el uso de plantillas sintácticas dinámicas (descritas en el avance 1). Esta etapa constituye la generación de la "feature" de entrada principal, contextualizando la relación lógica en una interrogante clínica coherente.
2. **Tokenización (Numerical Encoding):** A diferencia de la codificación *One-Hot* o *Label Encoding* utilizada en variables categóricas tradicionales —que resulta ineficiente para vocabularios extensos—, se utilizó el **Tokenizador BPE (Byte-Pair Encoding)** específico del modelo Llama 3. Este proceso convierte la cadena de texto Q en una secuencia de enteros $X = [t_1, t_2, \dots, t_n]$ donde cada t_i representa un fragmento de palabra. Esta codificación es fundamental para proyectar la entrada discreta en el espacio vectorial continuo del modelo.

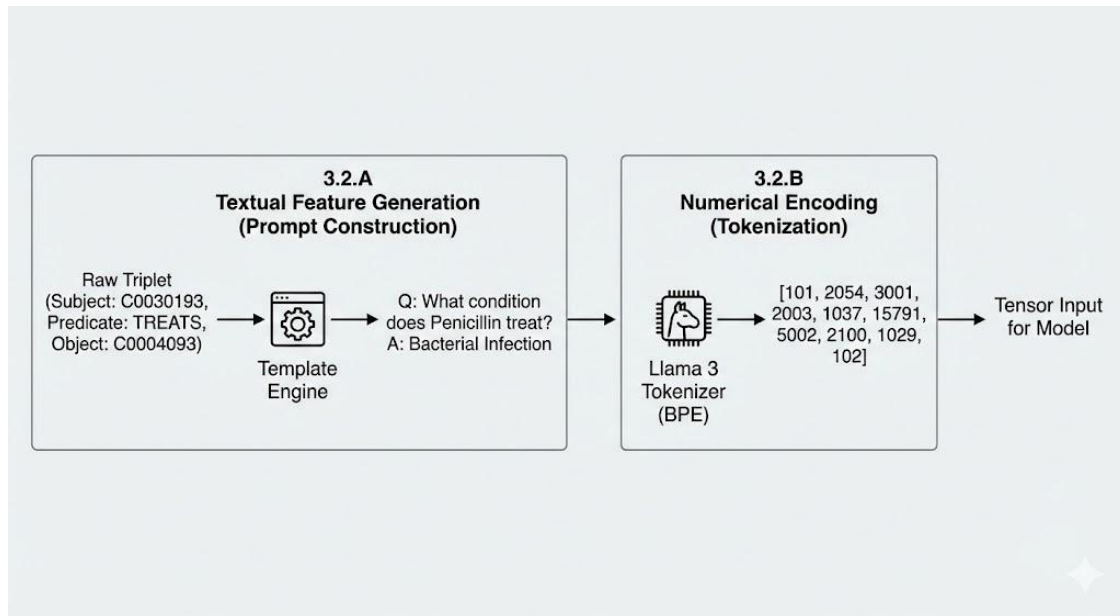


Ilustración 2 Proceso de creación de características y tokenización.

4. Ingeniería de variable Objetivo (Target Discretation)

Para aplicar técnicas de aprendizaje contrastivo (necesarias para el cálculo del vector de dirección), fue necesario transformar la métrica continua de evaluación en una variable de clase binaria.

- **Discretización (Binning):** Se partió de la variable continua **Similarity** ($S \in [0, 1]$), obtenida mediante la comparación de cosenos con S-BERT. Se aplicó una función de *umbralización* (*thresholding*) para generar la etiqueta binaria $Y_{Correct}$ (Correct_Flag):

$$Y = \begin{cases} 1 & \text{si } S \geq 0.7 \text{ (Conocimiento retenido)} \\ 0 & \text{si } S < 0.7 \text{ (Alucinación / Error)} \end{cases}$$

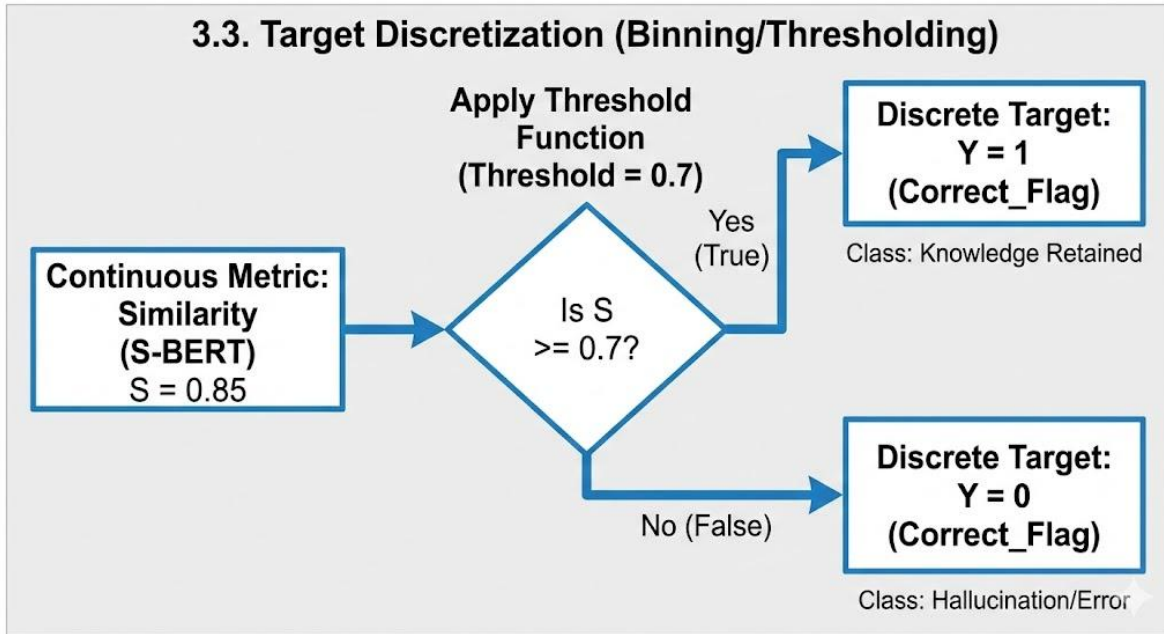


Ilustración 3 Proceso de Target Discretization

Justificación: Esta discretización permite separar el espacio de activaciones en dos distribuciones distintas (μ_{pos}, μ_{neg}); un requisito indispensable para aislar la dirección de la veracidad dentro de la red.

5. Extracción de características latentes (Feature extraction)

En lugar de utilizar características externas, este proyecto extrae las características internas generadas por el propio modelo durante el proceso de inferencia. Este procedimiento es análogo al Análisis Factorial (FA), donde se buscan variables latentes no observables que expliquen el comportamiento de los datos.

- **Extracción de Activaciones (Internal States):** Se define la función de extracción $\varphi(x, l)$ que captura el estado oculto (residuo) del modelo en la capa l para la entrada X . Para cada pregunta en el dataset, se obtiene un tensor de activaciones $h_l \in R_{model}$, donde $d_{model} = 4096$ para Llama 3.

Estas activaciones h_l constituyen el nuevo conjunto de características de alta dimensionalidad sobre las cuales se realizará el análisis.

- **Agregación de Características (Steering Vector Computation):** Para sintetizar las características relevantes asociadas a la veracidad, se calcula el **Vector de dirección** (v). Este vector representa la diferencia de medias entre las poblaciones definidas en la etapa.

$$v = \frac{1}{N_{pos}} \sum_{i \in Y=1} h_l(x_i) - \frac{1}{N_{neg}} \sum_{j \in Y=0} h_l(x_j)$$

Justificación: Esta operación algebraica extrae la "dirección semántica" que distingue una respuesta correcta de una incorrecta, comprimiendo la información de miles de ejemplos en una sola característica direccional robusta.




Ilustración 4 Extracción de características.

6. selección de características y reducción de dimensionalidad.

Dado que el espacio de características es de alta dimensión (4096 dimensiones por capa X 32 capas), se aplican métodos estadísticos para reducir la complejidad y seleccionar las características más informativas.

- **Análisis de Componentes Principales (PCA):** Se emplea PCA no como técnica de pre-procesamiento para entrenamiento, sino como herramienta de **validación y visualización de separabilidad**. Se proyectan los tensores de activación h_l de un plano R2.
 - **Objetivo:** Verificar visualmente si los clusters definidos por $Y = 0$ y $Y = 1$ son linealmente separables en el espacio latente. Si el PCA muestra una separación clara, se confirma que las características extraídas contienen información semántica relevante sobre la veracidad.
- **Selección de Capas (Feature Selection):** Un LLM procesa la información jerárquicamente. No todas las capas (variables) contribuyen igual a la formación de la respuesta factual. Se aplica un criterio de selección basado en la **precisión de sondaje (probing accuracy)**. Se entrena un clasificador lineal simple (regresión logística) sobre las activaciones de cada capa para predecir Y .
 - **Criterio:** Se selecciona la capa L^* que maximice la precisión de clasificación, descartando las capas iniciales (que procesan sintaxis superficial) y las finales (que preparan la salida de tokens). Esto reduce drásticamente el espacio de búsqueda para la intervención, optimizando la eficiencia computacional.

Conclusiones:

La ejecución de las fases de Extracción, Transformación, Evaluación e Ingeniería de Características marca el cierre de la etapa de "Data Preparation" dentro del ciclo de vida CRISP-ML (*Cross-Industry Standard Process for Machine Learning*). Las conclusiones clave de este proceso son:

1. **Garantía de Integridad y Calidad:** Se ha mitigado el riesgo de "Garbage In, Garbage Out" mediante un filtrado temporal estricto (2010-2024) y una validación semántica automatizada. Los datos que alimentan la fase de modelado poseen una alta fidelidad con respecto al consenso médico actual.
2. **Adaptabilidad de la Ingeniería de Características:** Se ha demostrado que los principios de la ingeniería de características tradicional son aplicables a la IA Generativa mediante una reinterpretación matemática. La conversión de texto a tokens, la discretización de la métrica de similitud y la extracción de activaciones latentes constituyen un pipeline de procesamiento robusto.

3. **Viabilidad del Modelado:** El análisis preliminar y la extracción de vectores sugieren que la información sobre la veracidad factual está codificada linealmente en el espacio latente del modelo (hipótesis de representación lineal). Esto valida el paso a la siguiente fase del ciclo CRISP-ML (Modelado y Evaluación), donde se implementarán las intervenciones de *Steering* para modular el comportamiento del modelo en tiempo real.

El proyecto cuenta ahora con los insumos estructurados (X_{tokens}), las etiquetas de supervisión (Y_{flag}) y la infraestructura de extracción de características (ϕ_{layers}) necesarias para proceder con los experimentos de control neuronal.

Anexos:

1.- Repositorio de github del proyecto.

Github Link:

https://github.com/MisaTecMNA/ProyectoIntegrador2026_Equipo18/tree/main