



**Tecnológico
de Monterrey**

**Proyecto integrador:
Avance 3. Baseline.**

Misael López Sánchez A01796906

**Proyecto Integrador MNA 2026
Equipo 18**

Partner:
Dra. Anthony Rios

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales

15/Enero/2026

Table of Contents

1. Introducción	2
2. Selección del Algoritmo y Justificación Metodológica.....	3
3. Análisis de Relevancia de Características: Diagnóstico mediante Linear Probing.	3
3.1 Resultados del Sondeo y Diagnóstico de Subajuste.	4
3.2 Conclusión de la relevancia de características.....	4
4. Definición de Estrategias de Inferencia (Baselines)	4
4.1 Zero-Shot Prompting (Limite inferior)	5
4.2 Few-Shot Prompting / In-Context Learning (Limite competitivo).....	5
4.3 Chain-of-Thought (CoT) Promting (Limite Superior Teorico).....	6
5. Métricas de Evaluación y Desempeño Mínimo Aceptable.	6
5.1 Métricas Seleccionadas.	6
Conclusiones:	7

1. Introducción

Una vez completada la ingeniería de características y la validación de los conjuntos de datos, el proyecto avanza hacia la fase de **Modelado y Evaluación Preliminar**. En el contexto de los Grandes Modelos de Lenguaje (LLMs), establecer una línea base (*baseline*) no implica simplemente entrenar un modelo clasificador simple, sino evaluar el comportamiento nativo de la arquitectura seleccionada, en este caso **Llama 3 8B**, bajo diferentes estrategias de inferencia (AI@Meta, 2024).

El objetivo central de esta sección es cuantificar la capacidad intrínseca del modelo para discernir la veracidad temporal de la información médica sin intervenciones mecánicas profundas. La literatura reciente sobre alucinaciones en LLMs sugiere que, si bien estos modelos poseen vasto conocimiento paramétrico, a menudo fallan en la recuperación precisa de hechos temporales debido a una representación interna difusa (Ji et al., 2023). Por tanto, es crucial determinar:

1.- El Límite Inferior (Lower Bound): ¿Cuál es el desempeño del modelo cuando opera "sin ayuda" (Zero-Shot)?

2.- El Límite Competitivo (State-of-the-Art): ¿Hasta dónde puede mejorar el modelo utilizando técnicas convencionales de inyección de contexto (Few-Shot y Chain-of-Thought)?

Esta evaluación comparativa justifica la necesidad técnica de implementar **Activation Steering**: si los métodos basados en *prompts*—que consumen más recursos computacionales—no logran resolver el problema de la alucinación de manera eficiente, la intervención directa en las representaciones latentes se valida como la solución óptima (Zou et al., 2023).

2. Selección del Algoritmo y Justificación Metodológica.

Para abordar la problemática de la alucinación temporal, se ha seleccionado el modelo **Llama 3 8B Instruct**. Esta elección se fundamenta en su arquitectura de *Transformer* optimizado que permite la extracción eficiente de estados ocultos para tareas de interpretabilidad (AI@Meta, 2024).

Sin embargo, para validar la hipótesis de que es necesaria una intervención externa, primero se debe diagnosticar el comportamiento interno del modelo. Para este fin, se empleó un enfoque de **Interpretabilidad Mecanística** mediante Sondeo Lineal (*Linear Probing*). Este método consiste en entrenar un clasificador lineal supervisado sobre las activaciones de la red para medir cuánta información sobre una característica específica (en este caso, el año del dato médico) es linealmente accesible (Alain & Bengio, 2016; Zou et al., 2023).

1.- Modelo Generativo (Backbone): Llama 3 para la extracción de características de alta dimensionalidad.

2.- Algoritmo de Sondeo (Probe): Regresión Logística Multinomial para evaluar la separabilidad lineal de la información.

Para el sondeo, se utilizó el algoritmo de **Regresión Logística** implementado en la biblioteca *Scikit-learn* (Pedregosa et al., 2011), seleccionado por su capacidad para ofrecer coeficientes interpretables que revelan la dirección de la característica en el espacio latente.

3. Análisis de Relevancia de Características: Diagnóstico mediante Linear Probing.

Antes de definir la línea base de desempeño, se ejecutó un análisis de importancia de características internas para responder a la pregunta de investigación: ***¿Está la información temporal codificada linealmente en el espacio latente del modelo?***

Se entrenó un clasificador lineal (W_{probe}) sobre las activaciones de la última capa oculta $h_L \in R^{4096}$ para predecir el año de origen de la afirmación médica $y \in 2010, \dots, 2024$

3.1 Resultados del Sondeo y Diagnóstico de Subajuste.

El análisis de los resultados obtenidos (Archivo: **probing_metrics.csv**) revela un fenómeno de **Subajuste Severo (Underfitting)** en la tarea de reconocimiento temporal.

- **Evidencia Cuantitativa:** El modelo lineal alcanzó un F1-Score (Micro) de 0.10 y una Precisión (Macro) de 0.09.
- **Comparativa con el Azar:** Para un problema de clasificación de 15 clases balanceadas (aprox. 14,000 muestras por año), el rendimiento aleatorio se sitúa en ≈ 0.066 . El modelo apenas supera el azar estadístico.

Año	Precision	Recall	F1-Score	Interpretación
2010	0.112	0.162	0.132	Baja separabilidad
2015	0.091	0.065	0.076	Ruido estadístico
2024	0.098	0.081	0.089	Sin señal clara

La incapacidad del Linear Probe para separar las clases demuestra que las características latentes en su estado natural no poseen relevancia suficiente para distinguir la temporalidad. Como señalan Zou et al. (2023) en su marco de Representation Engineering, cuando una característica no es linealmente accesible, el modelo tiende a alucinar o generar respuestas genéricas, lo cual confirma la necesidad de métodos de control más profundos como el Steering.

3.2 Conclusión de la relevancia de características.

La incapacidad del *Linear Probe* para separar las clases demuestra que las características latentes en su estado natural (h_L) no poseen relevancia suficiente para la tarea temporal. La información sobre el "tiempo" está diluida o entrelazada de forma no lineal. Esto justifica la necesidad de métodos más potentes que un simple clasificador: se requiere **Ingeniería de Prompts Avanzada** (Baselines) o **Manipulación de Vectores** (Steering).

4. Definición de Estrategias de Inferencia (Baselines)

Dado el diagnóstico anterior, se establecen tres líneas base que representan el estado del arte en inferencia sin re-entrenamiento (*training-free inference*). El desempeño del modelo propuesto (*Activation Steering*) se contrastará contra estos estándares.

4.1 Zero-Shot Prompting (Limite inferior)

El *Zero-Shot Learning* evalúa la capacidad del modelo para generalizar a tareas no vistas sin ejemplos explícitos, basándose únicamente en la distribución de probabilidad aprendida durante el pre-entrenamiento θ .

- **Fundamento matemático:**

Sea la consulta de entrada (ej. una pregunta médica) y I una instrucción de tarea. El modelo busca la secuencia de tokens de salida que maximice la probabilidad condicional:

$$y^* = \operatorname{argmax}_{P_{\theta}}(y|I, x)$$

Donde P_{θ} es la distribución parametrizada por el LLM.

- **Rol en el Experimento:** Representa el comportamiento "Vanilla" del modelo. Dado el bajo desempeño del *probing*, se espera que este baseline sufra de alucinaciones frecuentes, estableciendo el piso mínimo de rendimiento.

4.2 Few-Shot Prompting / In-Context Learning (Limite competitivo)

El aprendizaje en contexto (*In-Context Learning*) aprovecha la ventana de atención del Transformer para inducir una tarea mediante analogía. Se proporcionan k pares de ejemplos demostrativos $\mathcal{C} = \{(x_1, y_1), \dots, (x_k, y_k)\}$ antes de la consulta objetivo.

- **Fundamento Matemático:**

La inferencia se condiciona ahora sobre el contexto $\mathcal{C}$:

$$y^* = \operatorname{argmax}_{P_{\theta}}(y|\mathcal{C}, x)$$

Investigaciones recientes sugieren que el mecanismo de atención sobre actúa como un **meta-gradiente implícito**, ajustando temporalmente las activaciones del modelo para reducir la función de pérdida en la tarea actual sin modificar los pesos θ .

- **Rol en el Experimento:** Es el estándar industrial actual. Su desventaja radica en el costo computacional (aumenta linealmente el número de tokens de entrada). El objetivo del proyecto es igualar este rendimiento utilizando vectores de activación, que no consumen tokens de contexto.

4.3 Chain-of-Thought (CoT) Prompting (Limite Superior Teorico)

El método de "Cadena de Pensamiento" induce al modelo a generar una secuencia de pasos de razonamiento intermedio antes de producir la respuesta final y .

- **Fundamento Matemático:**

En lugar de mapear $x \rightarrow y$ directamente, el modelo aproxima la probabilidad marginalizando sobre los caminos de razonamiento latentes z :

$$P(y|x) = \sum_z P_\theta(y|z, x) P_\theta(z|x)$$

Esto permite al modelo descomponer problemas complejos (como verificar la fecha de un hecho) en pasos secuenciales más simples, reduciendo la carga cognitiva en cada paso de predicción.

- **Rol en el Experimento:** Se espera que CoT ofrezca el F1-Score más alto (mayor veracidad). Sin embargo, su alta latencia lo hace inviable para ciertas aplicaciones en tiempo real.

5. Métricas de Evaluación y Desempeño mínimo Aceptable.

Para evaluar la viabilidad de la solución en un contexto de negocio médico, se definen las siguientes métricas y criterios de éxito:

5.1 Métricas Seleccionadas.

1.- Recall (Sencibilidad): Prioritaria en medicina. Mide la fracción de hechos médicos verdaderos que el modelo logra recuperar correctamente.

$$Recall = \frac{TP}{TP + FN}$$

2.- F1-Score (Macro): Métrica principal de balance. Dado que el modelo puede tender a rechazar responder por seguridad (aumentando falsos negativos) o alucinar (aumentando falsos positivos), el F1-Score penaliza ambos extremos.

5.2 Criterios de Éxito y Desempeño Comparativo

Dado que técnicas como Few-Shot y Chain-of-Thought constituyen soluciones ya validadas en la literatura para la mitigación de alucinaciones, este proyecto no busca simplemente "optimizar" un modelo, sino evaluar la viabilidad técnica de una nueva aproximación: la intervención directa en el espacio latente (Activation Steering).

Por lo tanto, los criterios de éxito se definen en función de la capacidad de esta técnica novedosa para competir con los métodos tradicionales:

1. Umbral de Viabilidad (Límite Inferior) Para que la técnica de *Activation Steering* se considere funcional, debe superar obligatoriamente las métricas obtenidas en el diagnóstico de representaciones:

- **Referencia:** Desempeño de *Linear Probing* () y *Zero-Shot*.
- **Condición:** Si el Steering no supera significativamente este umbral, se refutará la hipótesis de que el vector de dirección ha capturado la semántica de la veracidad.

2. Umbral de Competitividad (Comparativa con el Estado del Arte) El objetivo central es contrastar el desempeño del *Activation Steering* frente a las técnicas consolidadas (*Few-Shot* y *CoT*).

- **Hipótesis de Investigación:** Se busca demostrar si la manipulación de tensores internos puede lograr una precisión semántica comparable a la inyección de contexto explícito.
- **Criterio de Éxito del Proyecto:** Se considerará exitosa la implementación si el *Activation Steering* logra posicionarse estadísticamente en el mismo rango de desempeño que el *Few-Shot Learning* (el estándar de la industria).
 - *Nota:* A diferencia de los métodos de *prompting* que dependen de la longitud del contexto, el éxito del Steering validaría una nueva forma de control de modelos que es agnóstica a la ventana de contexto.

3. Análisis de Eficiencia (Valor Añadido) De manera secundaria, si se logra la competitividad en métricas de veracidad (F1/Recall), se evaluará la eficiencia computacional como factor diferenciador. Se espera que el *Steering* ofrezca una ventaja significativa en latencia y costo de tokens frente a *Few-Shot* y *Chain-of-Thought*, al no requerir el procesamiento de ejemplos extensos en cada inferencia.

Conclusiones:

El análisis diagnóstico y la definición de la estrategia comparativa permiten concluir que el reconocimiento temporal en modelos de lenguaje médico es un desafío que excede

las capacidades nativas de la arquitectura ($F1 \approx 0.10$ en *Linear Probing*). Esta baja separabilidad lineal confirma que la solución no reside en ajustes superficiales, sino que requiere intervenciones profundas.

Por consiguiente, el proyecto ha formalizado su hipótesis central: **determinar si la intervención directa en el espacio latente (*Activation Steering*) puede constituir una alternativa viable y competitiva frente a las técnicas de inyección de contexto (*In-Context Learning*).**

Al establecer a *Few-Shot* y *Chain-of-Thought* como los estándares de desempeño a igualar (y no solo como modelos a superar por eficiencia), el proyecto se posiciona como un experimento riguroso de Ingeniería de Representaciones. El éxito de la siguiente fase no se medirá únicamente por la precisión de la respuesta, sino por la capacidad de demostrar que la manipulación de tensores internos es funcionalmente equivalente al razonamiento inducido por *prompts*, validando así una nueva metodología para el control de la veracidad en Inteligencia Artificial Generativa.

Referencias:

- AI@Meta. (2024). *Llama 3 Model Card*. GitHub. https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md
- Alain, G., & Bengio, Y. (2016). *Understanding intermediate layers using linear classifier probes*. arXiv preprint arXiv:1610.01644. <https://arxiv.org/abs/1610.01644>
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901. <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>
- Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), 1-38. <https://doi.org/10.1145/3571730>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Scikit-learn developers. (s.f.). *sklearn.linear_model.LogisticRegression*. Scikit-learn 1.4.1 documentation. Recuperado el 15 de enero de 2026, de https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html

- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837. https://proceedings.neurips.cc/paper_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html
- Zou, A., Phan, L., Chen, S., Campbell, J., Guo, P., Ren, R., ... & Hendrycks, D. (2023). Representation engineering: A top-down approach to AI transparency. *arXiv preprint arXiv:2310.01405*. <https://arxiv.org/abs/2310.01405>

Github Link:

https://github.com/MisaTecMNA/ProyectoIntegrador2026_Equipo18/tree/main