



**Tecnológico
de Monterrey**

**Proyecto integrador:
Avance 4. Modelos Alternativos.**

Misael López Sánchez A01796906

**Proyecto Integrador MNA 2026
Equipo 18**

Partner:
Dr. Anthony Rios

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales

22/Febrero/2026

Table of Contents

- 1. Introducción2
- 2. Metodología de Modelado: Definición Matemática de las Estrategias.....3
 - 2.1 Modelo 1: Zero-Shot Prompting (Inferencia Directa).....3
 - 2.2 Modelo 2: Few-Shot Prompting (In-Context Learning)3
 - 2.3 Modelo 3: Chain-of-Thought (CoT) Reasoning.....4
- 3. Resultados experimentales y evaluación de desempeño.....4
 - 3.1. Análisis de Resultados por Modelo.4
 - 1.- Desempeño del Zero-Shot:.....4
 - 2.- Desempeño del Few-Shot (Mejora Relativa):5
 - 3.- Colapso del Chain-of-Thought (CoT):.....5
- 4. Selección de Modelos y Ajuste Final.5
 - 4.1 Justificación del “Ajuste” hacia activation Steering.5
- Conclusiones.5

1. Introducción

En la continuidad del ciclo de vida de desarrollo de sistemas de Inteligencia Artificial, la fase de **Construcción de Modelos** adquiere una dimensión particular cuando se trabaja con Grandes Modelos de Lenguaje (LLMs). A diferencia del aprendizaje supervisado tradicional, donde se entrenan múltiples algoritmos desde cero, en este proyecto la construcción de modelos se reinterpreta como el diseño y la validación rigurosa de Estrategias de Inferencia sobre una arquitectura pre-entrenada **Llama 3 8B** (AI@Meta, 2024).

El objetivo de este avance es evaluar empíricamente la capacidad del modelo base para resolver la problemática de la alucinación temporal médica bajo distintas configuraciones arquitectónicas: **Zero-Shot**, **Few-Shot** y **Chain-of-Thought**. A través de este análisis comparativo, se busca determinar si las técnicas convencionales de *Prompt Engineering* son suficientes para alcanzar los estándares de seguridad clínica, o si los resultados confirman la hipótesis de "ceguera de representación" planteada en fases anteriores.

2. Metodología de Modelado: Definición Matemática de las Estrategias.

Para cumplir con el requisito de exploración de algoritmos, se han modelado tres enfoques probabilísticos distintos sobre el mismo modelo base (θ), fundamentados en la literatura reciente de *In-Context Learning*.

2.1 Modelo 1: Zero-Shot Prompting (Inferencia Directa)

Este modelo representa la capacidad nativa del sistema. No se proporciona información auxiliar ni ejemplos, confiando plenamente en las capacidades emergentes del modelo pre-entrenado (Kojima et al., 2022).

- **Fundamento Matemático:** El modelo busca maximizar la probabilidad de la respuesta (el año de validación médica) condicionada únicamente por la pregunta de entrada x :

$$y^* = \operatorname{argmax} P_{\theta}(y|x)$$

- **Hipótesis:** Evalúa si el conocimiento paramétrico del modelo contiene la asociación exacta entre el hecho médico y su fecha sin necesidad de condicionamiento externo.

2.2 Modelo 2: Few-Shot Prompting (In-Context Learning)

Se construye un contexto $\mathcal{C}$ compuesto por $k = 3$ pares de ejemplos de preguntas y respuestas correctas $\{(x_1, y_1), (x_2, y_2), (x_3, y_3)\}$. Esta técnica se basa en la premisa de que los LLMs pueden aprender tareas nuevas en tiempo de inferencia sin modificar sus pesos (Brown et al., 2020).

- **Fundamento Matemático:** La inferencia se condiciona sobre el contexto y la pregunta. El mecanismo de atención del Transformer utiliza para reducir el espacio de búsqueda en el manifold de activaciones:

$$y^* = \operatorname{argmax} P_{\theta}(y|\mathcal{C}, x)$$

- **Hipótesis:** Siguiendo a Brown et al. (2020), se espera que los ejemplos actúen como un "gradiente virtual", orientando al modelo hacia el formato y tipo de razonamiento esperado.

2.3 Modelo 3: Chain-of-Thought (CoT) Reasoning.

Este modelo induce un proceso de razonamiento secuencial, donde se genera una cadena de pensamientos intermedios antes de la respuesta final. Esta metodología ha demostrado mejorar el desempeño en tareas de razonamiento complejo (Wei et al., 2022; Zhang et al., 2023).

- **Fundamento Matemático:** La probabilidad de la respuesta final se obtiene marginalizando sobre los posibles caminos de razonamiento z :

$$P(y|x) = \sum_z P_\theta(y|z, x) P_\theta(z|x)$$

- **Hipótesis:** Wei et al. (2022) sugieren que descomponer problemas complejos mejora la precisión. Se evalúa si el razonamiento explícito ayuda a recuperar fechas correctas en el dominio médico.

3. Resultados experimentales y evaluación de desempeño

Año (Clase)	Métrica	Modelo 1: Zero-Shot	Modelo 2: Few-Shot	Modelo 3: Chain-of-Thought
2010	F1-Score	0.0444	0.0000	0.0000
	Recall	0.0247	0.0000	0.0000
2011	F1-Score	0.0253	0.0652	0.0000
	Recall	0.0141	0.0423	0.0000
2012	F1-Score	0.0000	0.0000	0.0408
2014	F1-Score	0.0000	0.1087	0.0000
	Recall	0.0000	0.0769	0.0000
Promedio Global	Macro F1	~0.035	~0.058	~0.012

3.1. Análisis de Resultados por Modelo.

1.- Desempeño del Zero-Shot:

Los resultados muestran un desempeño cercano al ruido aleatorio. Con un F1-Score promedio inferior al **0.05**, el modelo demuestra una incapacidad casi total para situar temporalmente los hechos médicos. Esto es consistente con las limitaciones de los modelos "base" para tareas de conocimiento específico sin recuperación externa (Kojima et al., 2022).

2.- Desempeño del Few-Shot (Mejora Relativa):

Este modelo presentó el mejor comportamiento relativo, alcanzando picos de F1-Score de **0.1087** en el año 2014. La inyección de ejemplos ayudó al modelo a entender el formato de salida, validando parcialmente la teoría de *In-Context Learning* de Brown et al. (2020). Sin embargo, en términos absolutos, un F1 del 10% sigue siendo inaceptable para una aplicación médica crítica.

3.- Colapso del Chain-of-Thought (CoT):

Contrario a la literatura general (Wei et al., 2022), el modelo CoT obtuvo un desempeño casi nulo. Al forzar al modelo a "razonar" sobre datos que no recuerda, se produce un fenómeno de amplificación de error o "alucinación en cascada". Esto sugiere que el CoT es efectivo para razonamiento lógico, pero no necesariamente para recuperación de hechos puros si la base de conocimiento está difusa (Zhang et al., 2023).

4. Selección de Modelos y Ajuste Final.

Siguiendo la metodología de selección, se descarta el modelo **Chain-of-Thought** debido a su inestabilidad observada. Se seleccionan los dos mejores candidatos para el análisis final:

1. **Few-Shot (In-Context Learning):** Por tener el mejor desempeño numérico (Brown et al., 2020).
2. **Zero-Shot (Baseline):** Por ser el más eficiente en latencia.

4.1 Justificación del “Ajuste” hacia activation Steering.

Los resultados ($F1 < 0.11$) indican que el problema no es de calibración de hiperparámetros, sino de **Representación**. Los modelos basados en *Prompting* han alcanzado su límite teórico para esta tarea específica. Por lo tanto, se concluye que ajustar parámetros superficiales (como la temperatura) es insuficiente. Es necesario intervenir en las activaciones internas del modelo (AI@Meta, 2024), moviendo el enfoque del proyecto hacia el **Activation Steering**.

Conclusiones.

Tras la construcción y evaluación de tres arquitecturas de inferencia, se concluye que las estrategias convencionales (**Zero-Shot, Few-Shot y CoT**) son insuficientes para garantizar la veracidad temporal en el dominio médico.

Por lo tanto, se selecciona la arquitectura de **Llama 3 + Activation Steering** como el modelo definitivo a desarrollar. Esta decisión se fundamenta en que solo una intervención mecánica sobre los vectores de activación tiene el potencial teórico de superar las limitaciones de representación evidenciadas por los bajos puntajes de Recall y F1 obtenidos.

Referencias Bibliográficas.

- AI@Meta. (2024). *Llama 3 Model Card*. GitHub. https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md
- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901. <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>
- Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., & Iwasawa, Y. (2022). Large language models are zero-shot reasoners. *Advances in Neural Information Processing Systems*, 35, 22199-2213.
- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837. https://proceedings.neurips.cc/paper_files/paper/2022/hash/9d5609613524ecf4f15af0f7b31abca4-Abstract-Conference.html
- Zhang, Z., Zhang, A., Li, M., & Smola, A. (2023). Automatic chain of thought prompting in large language models. *arXiv preprint arXiv:2210.03493*.