



**Tecnológico
de Monterrey**

**Proyecto integrador:
Avance 5. Modelo Final.**

Misael López Sánchez A01796906

**Proyecto Integrador MNA 2026
Equipo 18**

Partner:
Dr. Anthony Rios

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales

01/Marzo/2026

Contents

Tabla de figuras2

Tablas2

1. Introducción3

2. Evaluación de Modelos Individuales (Baselines) y Análisis de Error3

 2.1. El "Baseline 2015" (Línea de Ignorancia)4

 2.2. Resultados Comparativos de los Modelos Individuales4

 2.3. Diagnóstico de Fallo Generalizado.....5

3. Construcción y Optimización del Modelo Final: Activation Steering.5

 3.1: Extracción del Vector Temporal (1_construct_vector_llama2.py).....5

 3.2: Validación Semántica (4_check_vector_vocabulary.py)6

 3.3: Optimización de Hiperparámetros y Calibración (7_find_sweet_spot.py).....6

 3.4: Evaluación de Métricas Finales en Datos no Vistos (6_generate_paper_metrics.py) .7

4. Conclusión y Selección Definitiva.....8

6. Referencias Bibliográficas.....9

Tabla de figuras

Figure 1 Proceso de comparación del modelo vs baseline4

Figure 2 Flujo de creación de vector de activación6

Figure 3 Proceso de encuentro del Sweet Spot7

Figure 4 Flujo del procesamiento completo de Activation Steering.....8

Tablas

Table 1 Comparativa Modelo vs Baseline 2154

1. Introducción

En el desarrollo de soluciones basadas en Grandes Modelos de Lenguaje (LLMs) para el dominio médico; la fase de selección del "Modelo Final" trasciende la simple elección de un algoritmo predictivo. Las instrucciones convencionales de *Machine Learning* sugieren la creación de modelos de ensamble (e.g., *Stacking* o *Blending*). Sin embargo, en arquitecturas paramétricas masivas como **Llama 3 8B**, combinar múltiples modelos independientes resulta computacionalmente prohibitivo y arquitectónicamente redundante.

Por lo tanto, en esta investigación se redefine el concepto de "Ensamble Heterogéneo" hacia un Ensamble de Representaciones Latentes. En lugar de promediar las salidas de distintos LLMs, se interviene mecánicamente la red base combinando su espacio semántico original con Vectores de Dirección Temporal inyectados en tiempo de inferencia (*Activation Steering*).

El presente entregable documenta el análisis exhaustivo de los modelos individuales base (evaluados mediante métricas de regresión del error), la justificación del colapso de las estrategias de *Prompting*, y la construcción, validación y calibración del modelo final de *Activation Steering*.

2. Evaluación de Modelos Individuales (Baselines) y Análisis de Error

Antes de proceder con la intervención del espacio latente, se evaluaron empíricamente cuatro estrategias que fungieron como "modelos individuales": **Zero-Shot**, **Few-Shot**, **Chain-of-Thought (CoT)** y **Linear Probe**.

Para medir rigurosamente la calidad de las predicciones, además de las métricas de clasificación (Precisión, Recall, F1), se introdujeron métricas de regresión de distancia: Error Absoluto Medio (**MAE**), Error Cuadrático Medio (**MSE**) y Raíz del Error Cuadrático Medio (**RMSE**).

2.1. El "Baseline 2015" (Línea de Ignorancia)

En ciencia de datos, para demostrar que un modelo realmente posee capacidad predictiva, debe superar a un *Dummy Regressor*. Se construyó un "Baseline 2015" que predice sistemáticamente el año 2015 (punto medio del conjunto de validación) para todos los abstractos médicos. Si un LLM presenta un error mayor a adivinar siempre 2015, se comprueba matemáticamente que el modelo está introduciendo "ruido" (alucinación) en lugar de recuperar conocimiento real.




Figure 1 Proceso de comparación del modelo vs baseline

2.2. Resultados Comparativos de los Modelos Individuales

Los resultados obtenidos sobre la muestra de resúmenes de *PubMed* ($max_length=1024$) revelan una falla sistémica en los métodos convencionales.

Table 1 Comparativa Modelo vs Baseline 215

Estrategia / Modelo	Muestras Válidas	MAE del Modelo	MAE Baseline del (2015)	RMSE del Modelo	RMSE del Baseline
Zero-Shot	586	3.0597	2.8003	4.0342	3.2900
Few-Shot	965	3.2788	2.7358	4.1657	3.2217
Chain-of-Thought	399	3.4236	2.9323	4.3586	3.4035
Linear Probe	200	2.9000	2.7400	3.7027	3.2249

Nota: Un MAE mayor indica una peor predicción.

2.3. Diagnóstico de Fallo Generalizado.

El análisis de la Tabla 1 es contundente y constituye la justificación central de esta fase:

1. **Fracaso de la Inferencia Textual:** En el 100% de los escenarios, el Error Absoluto Medio (MAE) de los modelos de Llama 3 es superior al de simplemente adivinar el año 2015.
2. **Alucinación en Cascada (CoT):** La estrategia de *Chain-of-Thought*, teóricamente superior, obtuvo el peor rendimiento (MAE = 3.42). Al forzar al modelo a razonar sobre fechas que no están linealmente codificadas en sus pesos, el modelo genera silogismos falsos sustentados con alta confianza.
3. **Subajuste Estructural:** Incluso el *Linear Probe* (entrenado sobre la última capa latente con características supervisadas) no logró superar la línea base, confirmando que la temporalidad no es linealmente separable de forma nativa.

Por consiguiente, se descarta el ajuste de hiperparámetros tradicionales (como temperatura o -ejemplos) sobre estas arquitecturas textuales, dando paso a la construcción del modelo final mediante *Activation Steering*.

3. Construcción y Optimización del Modelo Final: Activation Steering.

El modelo final se fundamenta en la metodología *EasySteer* y se concibe como un **ensamble entre los pesos estáticos del modelo y un vector de dirección semántica**.

La construcción de este modelo se dividió en cuatro pasos secuenciales y automatizados en: (*run_complete_pipeline.py*).

3.1: Extracción del Vector Temporal

En lugar de entrenar una red neuronal desde cero, se extrajo la "dirección temporal" directamente de la topología de la red.

- Se inyectaron contextos médicos situados en 2024 y contextos situados en 2015.
- Mediante un *Forward Hook*, se capturaron las activaciones de la capa latente (L_{16}).

- Se calculó la media de las diferencias vectoriales ($V_{time} = \frac{1}{N} \sum A_{2024} - A_{2015}$). Este vector aísla matemáticamente el concepto del paso del tiempo.




Figure 2 Flujo de creación de vector de activación

3.2: Validación Semántica

Para asegurar que el vector extraído codifica realmente información temporal y no ruido estadístico, se proyectó el vector mediante producto punto contra la matriz de vocabulario (*unembed matrix* o *lm_head*) del modelo Llama 3.

Esta validación es el equivalente a la "Importancia de Características" (Feature Importance) en árboles de decisión, asegurando la explicabilidad mecánica del vector antes de su ensamblaje.

3.3: Optimización de Hiperparámetros y Calibración

Cumpliendo con el requerimiento de ajuste de modelos, en el marco del *Activation Steering*, los hiperparámetros críticos no son los de la función de pérdida, sino:

- El Coeficiente de Inyección (α): La intensidad con la que el vector modifica el flujo latente.
- El Rango de Capas (L_{target}): Dónde se realiza la inyección.

Se evaluó un espacio de búsqueda continuo para el coeficiente $\alpha \in [0.0, -0.2, -0.4, -0.6, -0.8, -1.0]$ iterando sobre las capas de razonamiento medio-profundo (Capas 12 a 27).

El proceso iterativo determinó que el "Sweet Spot" óptimo es un coeficiente de -0.6. Valores más cercanos a cero (Baseline) no mitigan la alucinación, mientras que valores inferiores a -0.8 "rompen" la coherencia del modelo, destruyendo sus capacidades de lenguaje.




Figure 3 Proceso de encuentro del Sweet Spot

3.4: Evaluación de Métricas Finales en Datos no Vistos

Una vez ensamblado el vector de dirección temporal ($\alpha = -0.6$) sobre la arquitectura base, se evaluó el desempeño en predicciones libres comparando el estado "Baseline" contra el estado "Time_Erased/Steered".

Además del *F1-Score*, se midió la **Perplejidad (PPL)** del texto generado. La PPL es crucial en este tipo de intervenciones, ya que valores extremadamente altos indicarían que el modelo está generando secuencias ininteligibles ("sopa de letras"). Los resultados demostraron que el *F1-Score* general se estabiliza, logrando anular las inclinaciones incorrectas del modelo hacia el futuro, manteniendo la Perplejidad en rangos saludables ($100 < PPL < 400$). Esto valida que el modelo mantiene su fluidez gramatical biomédica mientras se suprime mecánicamente la alucinación temporal.




Figure 4 Flujo del procesamiento completo de Activation Steering

4. Conclusión y Selección Definitiva.

La evaluación demostró que las metodologías convencionales (Zero-Shot, Few-Shot, CoT) generan predicciones más inexactas que un clasificador nulo (*Dummy Regressor* predictivo de 2015). El intento de obligar al modelo a razonar contextualmente provocó una escalada del Error Absoluto Medio (MAE).

Para solventar esta limitación estructural, el modelo seleccionado como definitivo para este proyecto es la Arquitectura Llama 3 optimizada mediante Activation Steering Heterogéneo. Con un hiperparámetro de inyección calibrado en operando en las capas, esta aproximación demostró la capacidad de intervenir directamente en las representaciones latentes, corrigiendo los sesgos de conocimiento paramétrico sin incurrir en la degradación lingüística del modelo (Perplejidad estable), alineándose estrictamente con los requerimientos de seguridad y robustez del dominio clínico.

Los resultados finales del procesamiento del Activation Steering serán analizados y discutidos en la siguiente entrega de este proyecto.

6. Referencias Bibliográficas.

- 1.- AI@Meta. (2024). *Llama 3 Model Card*. GitHub. https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md
- 2.- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901. <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>
- 3.- Wei, J., Wang, X., Schuurmans, D., Bosma, M., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837.
- 4.-Zou, A., Phan, L., Chen, S., Campbell, J., Guo, P., Ren, R., ... & Hendrycks, D. (2023). Representation engineering: A top-down approach to AI transparency. *arXiv preprint arXiv:2310.01405*. <https://arxiv.org/abs/2310.01405>