



**Tecnológico
de Monterrey**

**Proyecto integrador:
Avance 6. Conclusiones Clave**

Misael López Sánchez A01796906

**Proyecto Integrador MNA 2026
Equipo 18**

Partner:
Dr. Anthony Rios

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales

08/Marzo/2026

Contents

Abstract.	2
1. Entendimiento del Problema y Procesamiento de Datos (Avances 0, 1 y 2)	3
2. Evaluación de Baselines y Modelos Alternativos (Avances 3 y 4)	4
3. Metodología: Activation Steering y Trazabilidad Experimental (Avances 5 y 6)	5
Fase 1: Activation Steering Puro (Control de Comportamiento)	5
Fase 2: Ground Truth Steering y Evasión Semántica	6
Fase 3: Diagnóstico Definitivo por Linear Probing	6
4. Conclusión Arquitectónica: Transición a RAG	8
4.1. Relevancia del Descubrimiento: Entrelazamiento Paramétrico y Evasión Semántica	8
4.2. Justificación Arquitectónica: La Necesidad Imperativa de RAG	8
4.3. Líneas de Investigación Futuras (Trabajo Futuro)	9
5. Análisis de Infraestructura y Presupuesto	10
5.1. Costo de la Solución Local (On-Premise) actual	10
5.2. Comparativa Financiera: Nube Pública (Proyección a 1 Año)	10
5.3. Justificación Final	11
6. Referencias Bibliográficas	11

Abstract

Este proyecto de investigación aborda el problema crítico de las alucinaciones temporales en Grandes Modelos de Lenguaje (LLMs) aplicados al dominio biomédico. Utilizando la base de datos SemMedDB del NIH, se diseñó un flujo de trabajo integral para evaluar si es posible "rebobinar el tiempo" en el modelo *Llama 3 (8B)* empleando la técnica de *Activation Steering* (Ingeniería de Representaciones). A través de tres fases experimentales, se comprobó que, aunque es posible modificar la disposición del modelo, el conocimiento fáctico-temporal no es linealmente separable en el espacio latente, lo que provoca el fenómeno de "Evasión Semántica". Por consiguiente, se dictamina la inviabilidad del LLM como oráculo fáctico paramétrico y se justifica técnica y financieramente la transición a una arquitectura *Retrieval-Augmented Generation* (RAG) soportada por infraestructura local (NVIDIA RTX A6000).

1. Entendimiento del Problema y Procesamiento de Datos

(Avances 0, 1 y 2)

En la práctica clínica, la validez del conocimiento médico es estrictamente dependiente del tiempo. Un LLM consultado sobre tratamientos puede entregar respuestas que combinan hechos del año 2010 con descubrimientos del 2024, generando un riesgo crítico (alucinación anacrónica).

Para analizar y mitigar este comportamiento, se estableció un marco de datos riguroso:

1. **Fuente de Datos (SemMedDB):** Se extrajo información del repositorio SemMedDB del *National Institutes of Health* (NIH). Se procesó un conjunto de datos crudo construyendo más de 1 millón de tripletas semánticas estructuradas como Sujeto - Predicado - Objeto (ej. *Alloxan* - *ADMINISTERED_TO* - *Mice*), asociadas a metadatos de años de publicación estrictos.
2. **Generación de Lenguaje Natural (NLG):** Las tripletas se convirtieron en consultas (*prompts*) médicas estructuradas (ej. "*To which species is Alloxan typically administered?*") para poder interactuar y evaluar el conocimiento del modelo.
3. **Ingeniería de Características en LLMs:** A diferencia del Machine Learning tabular, aquí la ingeniería consistió en la tokenización de los *prompts*, la extracción de activaciones latentes de las capas intermedias del LLM () y la discretización de las métricas de similitud (ROUGE-L) para evaluar si el modelo conocía o ignoraba un hecho.




Ilustración 1 Flujo de obtención y procesamiento de datos

2. Evaluación de Baselines y Modelos Alternativos (Avances 3 y 4)

Antes de intervenir mecánicamente el modelo, se evaluó si las técnicas estándar de *Prompt Engineering* podían forzar al modelo a restringir su conocimiento a un año específico (ej. "Actúa como si estuvieras en 2015"). Se implementaron tres baselines:

- **Zero-Shot Prompting:** Falló sistemáticamente. La mera instrucción contextual no fue suficiente para aislar los pesos paramétricos específicos de un año. El modelo sufría de "fugas temporales" (*temporal leaks*), entregando información de 2024.
- **Few-Shot Prompting (In-Context Learning):** Se inyectaron ejemplos de respuestas temporalmente correctas. Hubo una mejora marginal en el formato, pero persistió la alucinación de entidades biomédicas más recientes.
- **Chain-of-Thought (CoT):** Se instruyó al modelo a "pensar paso a paso" razonando sobre la fecha. El resultado fue un colapso lógico: el modelo intentaba racionalizar cómo un hecho actual podía ser cierto en el pasado, generando explicaciones médicas absurdas.

Justificación del Pivote: El fracaso de estas técnicas demostró que el contexto externo no puede anular la memoria paramétrica interna del LLM. Por ello, se

transicionó hacia el **Activation Steering**, buscando intervenir el modelo "desde adentro".




Ilustración 2 Baseline y modelos alternativos

3. Metodología: Activation Steering y Trazabilidad Experimental (Avances 5 y 6)

Se implementó el framework **EasySteer** (ZJU-REAL) sobre la biblioteca de inferencia vLLM (en precisión bfloat16). Esta técnica permite extraer Vectores de Activación (*Steering Vectors*) usando la diferencia de medias (*DiffMean*) entre un estado de "aceptación" y uno de "rechazo temporal", inyectando este vector directamente en los grafos de computación durante el *forward pass* (capas 12-28).

La experimentación se estructuró en tres fases de descubrimiento crítico:

Fase 1: Activation Steering Puro (Control de Comportamiento)

- **Diseño:** Se extrajo un vector de "rechazo temporal" genérico y se inyectó para forzar al modelo a operar con "amnesia" posterior a un año de corte.

- **Resultados:** El comportamiento de estilo se modificó con éxito (el modelo usaba frases como *"1990s research indicates..."*). Sin embargo, falló drásticamente en la precisión fáctica.
- **Ejemplo Clínico:** Al consultar sobre "Alloxan" (cuyo *Ground Truth* en 2016 era *Mice*), el modelo alucinó la respuesta "Rats". La intervención actuó como un interruptor abrupto, corrompiendo la recuperación de la entidad.

Fase 2: Ground Truth Steering y Evasión Semántica

- **Diseño:** Para descartar que el error proviniera del vector general, se creó un *Golden Dataset*. Se usó la métrica ROUGE-L (>0.3) para filtrar exclusivamente hechos médicos que el modelo sí conocía. Los vectores se calcularon sobre esta verdad absoluta.
- **Resultados (Tabla 1):** Al aplicar coeficientes severos de supresión (-1.0 a -3.0), se descubrió el fenómeno de **"Evasión Semántica"**.

Tabla 1. Métricas de Intervención (Ground Truth Steering - Muestra 2010/2016)

Coeficiente	Tasa de Rechazo (Refusal)	Perplejidad Media (PPL)	Fenómeno Clínico Observado (Evasión)
-1.0	0%	~1.35	Reemplazó entidades específicas por agrupaciones genéricas (ej. respondió "Cells" en lugar del Ground Truth "Renal Cell").
-3.0	0%	~1.38	Mantuvo estabilidad lingüística perfecta (PPL bajo). Evadió el hecho exacto bloqueado, pero nunca se negó a responder.

Fase 3: Diagnóstico Definitivo por Linear Probing

- **Diseño:** Para entender *por qué* el modelo evadía semánticamente en lugar de aislar el año, se entrenaron clasificadores de Regresión Logística (*Linear Probing*) sobre los estados ocultos (*hidden states*) para predecir el año de un evento.
- **Resultados (Tabla 2):** Los F1-Scores oscilaron entre el 5% y el 11%.

Tabla 2. Resultados de Clasificación Temporal (Linear Probing sobre Estados Latentes)

Año (Clase)	Precisión	Recall	F1-Score	Soporte (Muestras)
2010	0.048	0.057	0.052	69
2013	0.089	0.119	0.102	67
2015	0.118	0.119	0.118	59

Conclusión Científica: Un F1-score de ~ 0.10 equivale a predecir al azar. Esto demuestra irrefutablemente que **el conocimiento fáctico-temporal no es linealmente separable**. Llama 3 entrelaza el tiempo y la semántica médica en espacios de alta dimensionalidad. Tratar de forzar al LLM a separar un año específico destruye la entidad biomédica adjunta.



Ilustración 3 Activation Steering y trazabilidad

4. Conclusión Arquitectónica: Transición a RAG

Los resultados obtenidos en este estudio desafían la premisa de que los Grandes Modelos de Lenguaje (LLMs) pueden ser manipulados de manera determinista en su espacio latente para fungir como bases de datos temporales estrictas. A continuación, se detallan las implicaciones de estos descubrimientos y la justificación del pivote arquitectónico.

4.1. Relevancia del Descubrimiento: Entrelazamiento Paramétrico y Evasión Semántica

La contribución más significativa de esta investigación es la documentación y caracterización empírica del fenómeno que hemos denominado **"Evasión Semántica"**.

Durante los experimentos de *Activation Steering* sobre la verdad base (*Ground Truth*), se demostró que el modelo Llama 3 (8B) no almacena el tiempo y el conocimiento biomédico como características ortogonales (independientes). Los resultados del *Linear Probing* (F_1 entre 0.05 y 0.11 sobre los estados ocultos ϕ_{layers}) prueban matemáticamente que el año de un evento médico no es linealmente separable de la entidad misma.

Al aplicar un vector de supresión severo (coeficientes de -1.0 a -3.0), el modelo se enfrentó a un conflicto latente. En lugar de colapsar sintácticamente (la Perplejidad se mantuvo estable en ~ 1.3) o emitir una negación formal (*Refusal Rate* del 0%), el LLM navegó por el *manifold* de alta dimensionalidad hacia conceptos taxonómicamente superiores o adyacentes (ej. sustituyendo "Célula Renal" por "Células"). Este hallazgo es crítico para la comunidad científica: **demuestra que las intervenciones latentes lineales son eficaces para alterar atributos de comportamiento (tono, estilo, seguridad), pero son fundamentalmente destructivas cuando se aplican a la supresión de recuperación fáctica-temporal.**

4.2. Justificación Arquitectónica: La Necesidad Imperativa de RAG

Frente a la inviabilidad del LLM como un "oráculo temporal paramétrico", la transición hacia una arquitectura **Retrieval-Augmented Generation (RAG)** deja de ser una alternativa y se convierte en una necesidad imperativa para entornos clínicos.

El pivote arquitectónico se justifica bajo el principio de **separación de responsabilidades**:

1. **Descarga Memorística:** El LLM ya no será responsable de almacenar ni recuperar fechas o hechos exactos. Esta tarea determinista se delegará a una base de datos vectorial construida directamente sobre la ontología de SemMedDB.
2. **Explotación del Razonamiento:** Como demostraron las métricas de Perplejidad, el motor de procesamiento de lenguaje y razonamiento sintáctico de Llama 3 es excepcionalmente robusto, incluso bajo estrés latente. En el ecosistema RAG, el modelo actuará puramente como un sintetizador lógico que procesa el contexto biomédico inyectado externamente, eliminando el riesgo de alucinaciones anacrónicas por "fugas" de sus pesos pre-entrenados.

4.3. Líneas de Investigación Futuras (Trabajo Futuro)

Este proyecto abre múltiples vías inexploradas para la investigación en Inteligencia Artificial aplicada a la salud, que pueden ser el núcleo de futuras publicaciones científicas:

- **A. Exploración de Intervenciones Latentes No-Lineales (SAEs):** Dado que el *Linear Probing* fracasó, una línea de investigación natural es el uso de *Sparse Autoencoders* (SAEs) para intentar desenredar (*disentangle*) el conocimiento fáctico de los metadatos temporales en subespacios no lineales, buscando aislar características monosemánticas.
- **B. Formalización de la Métrica de "Evasión Semántica":** El comportamiento documentado en este estudio sugiere la necesidad de crear nuevas métricas de evaluación para modelos intervenidos. Investigar cómo cuantificar el "desplazamiento semántico" (la distancia taxonómica entre la respuesta evadida y el *Ground Truth*) podría convertirse en un nuevo estándar para evaluar la robustez del *Steering*.
- **C. Arquitecturas T-RAG (Temporal RAG) en Biomedicina:** El desarrollo de bases de datos vectoriales que incorporen funciones de decaimiento temporal en la métrica de similitud del coseno. Esto permitiría que el sistema de recuperación no solo busque relevancia semántica, sino que pondere cronológicamente los resultados biomédicos antes de inyectarlos al LLM.

5. Análisis de Infraestructura y Presupuesto

Para llevar este pipeline a producción (soportar vLLM, procesar *Activation Steering* capa por capa y preparar el ecosistema RAG con bases de datos vectoriales), se ha determinado un requerimiento técnico innegociable de ~96 GB de VRAM consolidada.

5.1. Costo de la Solución Local (On-Premise) actual

La experimentación y validación se ejecutó en la infraestructura *bare-metal* de la Universidad (UTSA).

- **Hardware:** 2x Tarjetas Gráficas NVIDIA RTX A6000 (Arquitectura Ampere, 48 GB VRAM c/u).
- **Costo de Adquisición (CapEx):** ~\$4,500 USD por GPU + Estación de Trabajo. **Total estimado: ~\$13,000 USD (Inversión única).**
- **Costo de Operación (OpEx):** \$0.00 USD/hora marginal.

5.2. Comparativa Financiera: Nube Pública (Proyección a 1 Año)

Para dimensionar el impacto financiero, se cotizó la replicación de este entorno (~96 GB VRAM) en proveedores de nube operando 24/7 (730 horas/mes).

Tabla 3. Comparativa de Costos de Infraestructura LLM (On-Premise vs Nube)

Proveedor	Instancia Equivalente	Hardware GPU	Costo x Hora	Costo Anual Estimado (OpEx)
Local (NVIDIA)	Estación de Trabajo UTSA	2x RTX A6000 (96 GB)	\$0.00	~\$13,000 (Pago único CapEx)
AWS	g5.12xlarge	4x NVIDIA A10G (96 GB)	~\$5.67 USD	~\$49,668 USD
Azure	Standard_NC48ads_v4	2x NVIDIA A100 (160 GB)*	~\$7.35 USD	~\$64,380 USD
GCP	a2-highgpu-2g	2x NVIDIA A100 (80 GB)	~\$7.35 USD	~\$64,380 USD

(Nota: Azure y GCP obligan a instanciar pares de A100 corporativas, elevando drásticamente el piso de entrada. Las GPUs de rango estación de trabajo como la RTX A6000 no están disponibles en la nube de capa 1).

5.3. Justificación Final

El análisis financiero y técnico es irrefutable: la infraestructura local basada en **2x NVIDIA RTX A6000** es la opción definitiva.

1. Operar en la nube pública representaría un gasto insostenible de entre \$50,000 y \$64,000 USD anuales solo en experimentación. El hardware local ofrece un ROI de recuperación en menos de 3 meses.
2. El acceso *bare-metal* permite la manipulación directa de procesos vía Conda y nvidia-smi para inyectar *hooks* latentes en PyTorch, accesos que AWS SageMaker o GCP Vertex AI frecuentemente bloquean por sus capas de abstracción.

6. Referencias Bibliográficas

1. Zou, A., et al. (2023). *Representation Engineering: A Top-Down Approach to AI Transparency*. arXiv:2310.01405.
2. Turner, A., et al. (2023). *Activation Addition: Steering Language Models Without Optimization*. arXiv:2308.10248.
3. Kwon, W., et al. (2023). *Efficient Memory Management for Large Language Model Serving with PagedAttention (vLLM)*. Proceedings of the SOSP '23.
4. AI@Meta. (2024). *Llama 3 Model Card*. GitHub.
5. National Library of Medicine. *SemMedDB download*. U.S. National Institutes of Health.