



**Tecnológico
de Monterrey**

**Proyecto integrador:
Avance 7. Resumen Ejecutivo**

Misael López Sánchez A01796906

**Proyecto Integrador MNA 2026
Equipo 18**

Partner:
Dr. Anthony Rios

Dra. Grettel Barceló Alonso
Dr. Luis Eduardo Falcón Morales

15/Marzo/2026

Contents

Abstract	2
SECCIÓN A: Síntesis Estratégica, Modelos y Recomendaciones.....	3
1. Síntesis del Problema (Fase de Entendimiento)	3
2. Hallazgos del Análisis Exploratorio de Datos (EDA)	4
3. Modelos Generados y el Descubrimiento Arquitectónico	5
Resumen de la evaluación de Modelos y Técnicas de Intervención Temporal	5
4. Recomendaciones Estratégicas y Mejora del Flujo de Investigación	6
SECCIÓN B: Análisis Costo-Beneficio y Tablas de Ahorro.....	7
1. Costos Incurridos por Fase (CRISP-ML)	7
2. Tabla Comparativa de Costos (Local vs. Nube Pública a 1 Año)	7
3. Beneficios Potenciales (ROI Indirecto)	8
SECCIÓN C: Riesgos y Desafíos de la Solución	8
1. Riesgos Relacionados con los Datos	8
2. Riesgos de Ataques	8
3. Riesgos de Prueba y Confianza.....	8
4. Riesgos de Cumplimiento (Compliance)	9
Matriz de Riesgos y Desafíos del Proyecto	9
Conclusiones Generales y Visión a Futuro	10
1. Relevancia y Aportaciones Científicas del Proyecto	10
2. Potencial Futuro y Líneas de Investigación	11
3. La Importancia de la Cooperación Académica	12

Abstract

En la era de la Inteligencia Artificial generativa, la adopción de Grandes Modelos de Lenguaje (LLMs) en el sector salud enfrenta un obstáculo técnico y ético crítico: las alucinaciones temporales. En la medicina basada en evidencia, mezclar tratamientos obsoletos de hace una década con descubrimientos actuales genera un riesgo inaceptable para la seguridad del paciente.

Este proyecto integrador investigó la viabilidad de emplear **Ingeniería de Representaciones (Activation Steering)** para intervenir mecánicamente el espacio latente del modelo Llama 3 (8B), con el objetivo de "rebobinar" su memoria paramétrica y forzarlo a emitir diagnósticos válidos a una fecha de corte específica. Utilizando el rigor de la base de datos clínica SemMedDB del *National Institutes of Health* (NIH), la investigación arrojó un descubrimiento empírico de alto impacto: **el conocimiento fáctico-temporal no es linealmente separable en la arquitectura de los LLMs**. Intentar suprimir cronologías internamente provoca un fenómeno de "Evasión Semántica", donde el modelo pierde su precisión médica.

A partir de este diagnóstico, el presente documento estratégico dictamina la inviabilidad de utilizar LLMs como oráculos fácticos independientes y justifica un pivote arquitectónico imperativo hacia un ecosistema GraphRAG (Retrieval-Augmented Generation basado en Grafos de Conocimiento).

Adicionalmente, se presenta un análisis financiero contundente que demuestra que el despliegue de esta arquitectura de IA en infraestructura local (On-Premise con GPUs NVIDIA RTX) no solo garantiza la soberanía y privacidad de los datos clínicos de los pacientes, sino que elimina la dependencia de la nube pública, generando **ahorros operativos superiores a los \$50,000 USD anuales** y logrando un Retorno de Inversión (ROI) en menos de tres meses.

SECCIÓN A: Síntesis Estratégica, Modelos y Recomendaciones

1. Síntesis del Problema (Fase de Entendimiento)

En la práctica clínica basada en evidencia, la validez del conocimiento es estrictamente dependiente de su cronología. Actualmente, los Grandes Modelos de Lenguaje (LLMs) presentan un riesgo crítico conocido como **alucinación anacrónica**: al ser consultados, mezclan tratamientos obsoletos (ej. 2010) con descubrimientos actuales (2024), comprometiendo la seguridad del paciente. El objetivo rector de este proyecto fue investigar si era técnica y matemáticamente posible "rebobinar el tiempo" en la memoria de un modelo paramétrico (Llama 3 8B) para forzarlo a responder con la verdad médica de un año de corte específico.

2. Hallazgos del Análisis Exploratorio de Datos (EDA)

Para garantizar el rigor científico, no se usaron datos sintéticos. Se recurrió a **SemMedDB**, el repositorio oficial de los Institutos Nacionales de Salud (NIH) de EE. UU.

- Se procesaron y limpiaron **más de 1 millón de tripletas semánticas** con estructura [Sujeto - Predicado – Objeto] (ej. *Alloxan - ADMINISTERED_TO - Mice*) vinculadas a fechas de publicación estrictas.
- Mediante algoritmos de Generación de Lenguaje Natural (NLG), estas tripletas se transformaron en consultas médicas estructuradas.
- **Hallazgo Clave:** Los datos estructurados biomédicos poseen una altísima fidelidad temporal, pero al alimentar a un LLM tradicional con ellos, el modelo sufre de "fugas", revelando su incapacidad nativa para segmentar su propia memoria por fechas.



Ilustración 1 Resumen del proceso del proyecto

3. Modelos Generados y el Descubrimiento Arquitectónico

La investigación evolucionó a través de tres niveles de complejidad para intentar controlar al modelo:

- 1. **Ingeniería de Prompts (Zero-Shot, Few-Shot, Chain-of-Thought):** Todos fracasaron. Incluso al pedirle al modelo que "razonara paso a paso" (CoT), este sufrió un colapso lógico, inventando justificaciones absurdas para encajar hechos de 2024 en el pasado.
- 2. **Activation Steering (Intervención Mecánica):** Se inyectaron vectores matemáticos directamente en el "cerebro" del modelo (espacio latente) utilizando el framework *EasySteer* y la infraestructura *vLLM*. Aunque el modelo adoptó un tono histórico, **destruyó la recuperación fáctica**, confundiendo medicamentos y especies.
- 3. **Linear Probing y Evasión Semántica (El Descubrimiento Definitivo):** Al someter los estados ocultos del modelo a clasificadores de regresión, obtuvimos un F1-Score del ~5%. Esto comprobó matemáticamente que **el tiempo no es linealmente separable en un LLM**. Al forzar al modelo, este recurrió a la "Evasión Semántica" (responder con generalidades vagas pero gramaticalmente perfectas para no mentir).

Resumen de la evaluación de Modelos y Técnicas de Intervención

Temporal

Método / Técnica Evaluada	Descripción de la Implementación	Rendimiento (Performance) y Resultados Observados	Conclusión / Impacto en el Modelo
1. Ingeniería de Prompts (Zero-Shot, Few-Shot, Chain-of-Thought)	Manipulación del contexto externo mediante instrucciones textuales. Se probó forzar al modelo a "razonar paso a paso" (CoT) limitando su conocimiento a un año específico.	Fracaso sistemático. Al usar CoT, el modelo sufrió un colapso lógico, inventando justificaciones médicas absurdas y forzadas para intentar encajar descubrimientos del año 2024 en el pasado.	El contexto externo es insuficiente para anular la memoria paramétrica interna del LLM. Genera alucinaciones anacrónicas severas.

2. Activation Steering <i>(Intervención Mecánica)</i>	Inyección directa de vectores matemáticos en las capas intermedias ("cerebro" o espacio latente) del modelo Llama 3 utilizando el framework <i>EasySteer</i> y <i>vLLM</i> .	Éxito parcial en estilo, fracaso fáctico. El modelo logró modificar su comportamiento para adoptar un tono histórico, pero destruyó la recuperación fáctica, confundiendo entidades críticas como medicamentos y especies de prueba.	Intervenir mecánicamente el modelo funciona para cambiar el comportamiento general, pero corrompe los hechos médicos exactos almacenados en los pesos.
3. Linear Probing <i>(Diagnóstico de Evasión Semántica)</i>	Entrenamiento de clasificadores de regresión aplicados directamente sobre los tensores de estados ocultos (<i>hidden states</i>) para predecir el año de un hecho.	Rendimiento deficiente (F1-Score ~5%). Ante el conflicto, el modelo no colapsa gramaticalmente, sino que aplica "Evasión Semántica": responde con generalidades vagas pero perfectas en sintaxis para evitar mentir.	Descubrimiento definitivo: Comprobación matemática de que el tiempo y el conocimiento biomédico no son linealmente separables en el espacio latente del LLM.

4. Recomendaciones Estratégicas y Mejora del Flujo de Investigación

Dado que forzar la memoria interna del LLM es inviable, proponemos las siguientes mejoras al flujo de investigación y arquitectura:

- **¿Es mejor usar otro algoritmo que no sea RAG tradicional?** Sí. Dado que nuestra fuente de datos (SemMedDB) se basa en tripletas (nodos y aristas), la recomendación a nivel empresarial es saltar el RAG vectorial clásico y adoptar **GraphRAG (Retrieval-Augmented Generation basado en Grafos de Conocimiento)**. GraphRAG permite navegar por las relaciones biomédicas y filtrar los nodos por su atributo de "Año", inyectando al LLM un contexto temporal 100% determinista y a prueba de alucinaciones.

- **¿Es necesario comprar más tarjetas NVIDIA?**
 - *Estado Actual:* Las **2x RTX A6000 (96 GB VRAM)** actuales fueron suficientes para experimentar con Llama 3 8B.
 - *Recomendación de Escalamiento:* Si la institución decide implementar GraphRAG o escalar hacia un modelo clínico más robusto (como Llama 3 70B o Llama 3.3), **sí será necesario adquirir más hardware**. Se sugiere expandir el servidor local a 4x RTX A6000 o transicionar a 2x NVIDIA H100. Esto evitará cuellos de botella al correr simultáneamente el LLM, la base de datos de grafos y los modelos de *embeddings* locales.

SECCIÓN B: Análisis Costo-Beneficio y Tablas de Ahorro

La estrategia de mantener el desarrollo *On-Premise* (local) en lugar de utilizar servicios gestionados en la nube ha generado un impacto financiero altamente favorable.

1. Costos Incurridos por Fase (CRISP-ML)

- **Fase 1 y 2 (Entendimiento de Negocio y Datos):** \$0 USD (Datos extraídos de fuente pública gubernamental).
- **Fase 3 y 4 (Preparación y Modelado):** ~\$13,000 USD de inversión de capital (CapEx) correspondientes a la estación de trabajo y 2 GPUs NVIDIA RTX A6000 adquiridas por la UTSA. Software 100% Open Source.
- **Fase 5 y 6 (Evaluación y Despliegue):** \$0 USD operativo (OpEx marginal por electricidad), en contraposición al costo por hora de la nube.

2. Tabla Comparativa de Costos (Local vs. Nube Pública a 1 Año)

Para dimensionar el ahorro, se simuló el costo de replicar un entorno de 96 GB de VRAM en operación 24/7 (730 horas/mes).

Modalidad	Infraestructura / Proveedor	Costo Inicial (CapEx)	Gasto Operativo Mensual (OpEx)
Local (Estrategia Actual)	2x NVIDIA RTX A6000 (UTSA)	~\$13,000 USD	~\$0 USD <i>(Solo energía)</i>
Nube AWS	Instancia g5.12xlarge (4x A10G)	\$0 USD	~\$4,139 USD

Nube Azure	Instancia Standard_NC48ads	\$0 USD	~\$5,365 USD
------------	-------------------------------	---------	--------------

3. Beneficios Potenciales (ROI Indirecto)

1. **Retorno de Inversión (ROI) Acelerado:** La compra de los servidores locales NVIDIA se amortizó matemáticamente en el **tercer mes** de investigación comparado con los costos de AWS.
2. **Propiedad Intelectual (IP):** Operar localmente (Bare-Metal) permitió utilizar herramientas de bajo nivel como *EasySteer* para interceptar tensores, algo que los entornos gestionados de nube suelen bloquear.
3. **Seguridad Médica:** El modelo resultante (GraphRAG local) protege la privacidad del paciente (cumplimiento HIPAA nativo) al evitar que los *prompts* médicos viajen por internet a servidores de terceros (como OpenAI o Google Cloud).

SECCIÓN C: Riesgos y Desafíos de la Solución

A pesar de los beneficios operativos, la adopción de una arquitectura GraphRAG en infraestructura local conlleva riesgos críticos que se deben gestionar:

1. Riesgos Relacionados con los Datos

- **Contaminación de Nodos en SemMedDB:** Si el algoritmo de extracción de tripletas del NIH cometió errores al procesar *papers* originales (ej. relacionando incorrectamente un fármaco con un síntoma), el GraphRAG inyectará contexto falso al LLM. Se requiere auditoría clínica constante de la base de datos.

2. Riesgos de Ataques

- **Data Poisoning y Prompt Injection:** Dado que el RAG buscará activamente en la base documental, un ataque cibernético que logre modificar los metadatos de los artículos (cambiando el año 2024 por 2010) evadirá el control de la IA. Asimismo, usuarios maliciosos podrían estructurar *prompts* engañosos para forzar al LLM a ignorar el contexto inyectado.

3. Riesgos de Prueba y Confianza

- **Rechazo Clínico por la "Caja Negra":** Los médicos son reacios a tomar decisiones basadas en IA si no pueden auditar el proceso.

- **Mitigación:** La ventaja de transicionar de *Activation Steering* a *GraphRAG* es la trazabilidad. Es imperativo desarrollar una interfaz de usuario que obligue al LLM a incluir "citas en línea" (ej. *[SemMedDB ID: 10452, Año: 2015]*).

4. Riesgos de Cumplimiento (Compliance)

- **Regulaciones Locales (HIPAA / LFPDPPP):** Operar con NVIDIA locales resuelve la soberanía del dato, pero la seguridad física del servidor, el cifrado de los discos duros y los controles de acceso por roles (RBAC) deben ser auditados por normativas hospitalarias. Una brecha de seguridad en el servidor Bare-Metal representa una responsabilidad legal completa para la institución.

Matriz de Riesgos y Desafíos del Proyecto

Categoría	Riesgo / Desafío Potencial	Probabilidad	Impacto	Estrategia de Mitigación
Datos	Contaminación de Nodos / Sesgos: Errores heredados de SemMedDB o fallos en el script de extracción de tripletas, inyectando relaciones médicas falsas al GraphRAG.	Media	Alto	Implementar auditorías clínicas aleatorias sobre la base de datos de grafos y establecer un canal de reporte donde los médicos puedan marcar citas incorrectas para su corrección manual.
Ataques	Prompt Injection / Data Poisoning: Manipulación de consultas por usuarios o intrusiones a la base documental para alterar las fechas de los nodos, forzando al modelo a eludir el filtro temporal.	Media	Alto	Implementar <i>Guardrails</i> (filtros de seguridad de entrada/salida) en la API del LLM. Mantener la base de datos SemMedDB local en modo de solo lectura (Read-Only) para

				usuarios no administradores.
Prueba y Confianza	Rechazo Clínico (Efecto Caja Negra): Falta de adopción del sistema por parte del personal médico si las respuestas generadas carecen de explicabilidad o fuentes verificables.	Alta	Crítico	Condicionar los <i>prompts</i> del sistema para que el LLM tenga estrictamente prohibido responder sin incluir la cita en línea (Ej: [ID: 10452, Año: 2015]). Desarrollar una interfaz que enlace estas citas al paper original del NIH.
Cumplimiento	Brecha de Privacidad (HIPAA/LFPDPPP): Accesos no autorizados al servidor local (<i>bare-metal</i>) de NVIDIA que almacene historiales de consultas o datos sensibles de pacientes.	Baja	Crítico	Aplicar cifrado de grado militar para datos en reposo y en tránsito. Implementar Control de Acceso Basado en Roles (RBAC) y mantener el servidor aislado de la red pública de internet mediante firewalls estrictos.

Conclusiones Generales y Visión a Futuro

1. Relevancia y Aportaciones Científicas del Proyecto

Este proyecto integrador trasciende la mera implementación tecnológica para realizar una contribución empírica fundamental en el campo de la Inteligencia Artificial segura y la interpretabilidad mecanicista (*Mechanistic Interpretability*). Al abordar el problema

crítico de las alucinaciones temporales en la medicina, la investigación demostró de manera concluyente que **el conocimiento fáctico-temporal no es linealmente separable** en el espacio latente de Grandes Modelos de Lenguaje (LLMs) como Llama 3.

El descubrimiento y documentación del fenómeno de "**Evasión Semántica**" —donde el modelo bajo estrés de *Activation Steering* sacrifica la especificidad médica por la seguridad gramatical— sirve como una advertencia crucial para la industria: la memoria paramétrica interna de los LLMs no debe ser forzada para actuar como una base de datos relacional exacta.

Al dictaminar la inviabilidad de los LLMs puros para esta tarea, el proyecto aporta un inmenso valor estratégico al justificar arquitectónicamente el uso de Retrieval-Augmented Generation (RAG) o GraphRAG en infraestructura local (*On-Premise*). Esta solución no solo protege la privacidad del paciente y garantiza el determinismo clínico, sino que representa un ahorro proyectado superior a los \$50,000 USD anuales en costos de nube, demostrando una alineación perfecta entre rigor científico y viabilidad de negocio.

2. Potencial Futuro y Líneas de Investigación

El cierre de este ciclo metodológico no representa un fin, sino el punto de partida para ecosistemas clínicos más robustos. El futuro de este desarrollo se direcciona hacia tres horizontes:

- **Transición a GraphRAG Clínico:** Evolucionar la inyección de contexto mediante Grafos de Conocimiento (aprovechando la estructura de tripletas de SemMedDB), permitiendo a la IA razonar no solo sobre textos, sino sobre relaciones causales y temporales complejas.
- **Exploración No-Lineal (Sparse Autoencoders):** Investigar si el conocimiento temporal puede ser desenredado utilizando subespacios no lineales, llevando la interpretabilidad mecánica al siguiente nivel.
- **Despliegue de Agentes Médicos Autónomos:** Integrar este modelo validado en un entorno clínico real donde actúe como un copiloto de revisión de literatura, acelerando la investigación farmacológica y médica sin el riesgo de sesgos anacrónicos.

3. La Importancia de la Cooperación Académica

Los resultados obtenidos en esta investigación no habrían sido posibles sin la profunda sinergia institucional y la colaboración transfronteriza entre el Tecnológico de Monterrey y la University of Texas at San Antonio (UTSA).

Este proyecto es un testimonio vivo del poder de la cooperación académica internacional:

- Por un lado, el **Tec de Monterrey** aportó la visión de Inteligencia Artificial Aplicada, el rigor metodológico (CRISP-ML) y el enfoque de resolución de problemas complejos con impacto en la industria, guiado por la excelencia de sus asesores.
- Por otro lado, la UTSA proporcionó el entorno de investigación de frontera en Procesamiento de Lenguaje Natural (NLP) y, de manera crítica, el acceso a infraestructura *bare-metal* de alto rendimiento (clústeres NVIDIA RTX A6000), un recurso indispensable para ejecutar intervenciones profundas en el espacio latente de modelos paramétricos masivos.

La unión de estos dos ecosistemas académicos no solo permitió superar las barreras computacionales y teóricas, sino que enriqueció la formación investigativa, demostrando que los desafíos globales de la Inteligencia Artificial (como la seguridad y veracidad clínica) requieren alianzas estratégicas, recursos compartidos y una visión sin fronteras. Este proyecto sienta un precedente valioso para futuras colaboraciones que sigan posicionando a ambas instituciones a la vanguardia de la IA ética y aplicada.

Referencias Bibliográficas

1. **AI@Meta. (2024).** *Llama 3 Model Card*. GitHub. Recuperado de https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md
2. **Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020).** Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877-1901.
3. **Gao, X., Zhang, R., Du, D., Mahindire, S., Somayajula, S. A., & Xie, P. (2025).** Can prompts rewind time for LLMs? Evaluating the effectiveness of prompted knowledge cutoffs. *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*, 20786–20800. Association for Computational Linguistics.
4. **Hugging Face. (s.f.).** *Transformers: State-of-the-art Machine Learning for Pytorch, TensorFlow, and JAX*. Recuperado de <https://huggingface.co/docs/transformers>

5. **Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023).** Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), 1-38.
6. **Kojima, T., Gu, S. S., Reid, M., Matsuo, Y., & Iwasawa, Y. (2022).** Large language models are zero-shot reasoners. *Advances in Neural Information Processing Systems*, 35, 22199-22213.
7. **Kwon, W., Li, Z., Zhuang, S., Sheng, Y., Zheng, L., Yu, C. H., ... & Stoica, I. (2023).** Efficient Memory Management for Large Language Model Serving with PagedAttention (vLLM). *Proceedings of the 29th Symposium on Operating Systems Principles (SOSP '23)*.
8. **McKinney, W. (2010).** Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 51–56.
9. **National Library of Medicine. (s.f.).** SemMedDB download. U.S. National Institutes of Health. Recuperado de https://lhncbc.nlm.nih.gov/temp/SemRep_SemMedDB_SKR/SemMedDB_download.html
10. **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011).** Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
11. **Reimers, N., & Gurevych, I. (2019).** Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics.
12. **Roy, S. (2025).** Activation steering: A new frontier in AI control—But does it scale? *Hugging Face*.
13. **Turner, A., Thiergart, L., Udell, D., Leech, G., Mini, U., & MacDiarmid, M. (2023).** Activation Addition: Steering Language Models Without Optimization. *arXiv preprint arXiv:2308.10248*.
14. **Wei, J., Wang, X., Schuurmans, D., Bosma, M., Chi, E., Le, Q., & Zhou, D. (2022).** Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, 35, 24824-24837.
15. **ZJU-REAL. (2024).** EasySteer: A framework for efficient Activation Steering using vLLM. Repositorio de GitHub. Recuperado de <https://github.com/ZJU-REAL/EasySteer>
16. **Zou, A., Phan, L., Chen, S., Campbell, J., Braun, P., Center, W., ... & Hendrycks, D. (2023).** Representation Engineering: A Top-Down Approach to AI Transparency. *arXiv preprint arXiv:2310.01405*.